

Στόχος της Εργασίας

Στόχος της εργασίας είναι η μελέτη της επίδρασης της αναπαράστασης δεδομένων στην απόδοση ενός απλού ταξινομητή, χρησιμοποιώντας αποκλειστικά έναν ταξινομητή k-NearestNeighbors (k-NN). Η εργασία εστιάζει στη σχεδίαση και εκπαίδευση αναπαραστάσεων μέσω autoencoders, στη σύγκριση εκπαιδευμένων και προεκπαιδευμένων (off-the-shelf) embeddings, στην ποσοτική και ποιοτική ανάλυση των αποτελεσμάτων και σε μια μικρή ερευνητική ερώτηση.

Baseline: Αρχικός Χώρος Εικόνων

Στο πείραμα χρησιμοποιείται το σύνολο δεδομένων CIFAR-100, το οποίο αποτελείται από 100 κατηγορίες έγχρωμων εικόνων διαστάσεων 32×32 pixels. Από αυτές επιλέγονται τυχαία 10 κλάσεις, με σταθερό seed, ώστε η επιλογή να είναι αναπαραγώγιμη. Στη συνέχεια, φιλτράρονται τα σύνολα εκπαίδευσης και ελέγχου ώστε να διατηρηθούν μόνο τα δείγματα των επιλεγμένων κλάσεων και τα labels επαναχарτογραφούνται στο εύρος 0–9, μετατρέποντας το πρόβλημα σε ταξινόμηση 10 κατηγοριών. Οι τιμές των pixel κανονικοποιούνται διαιρώντας με το 255.0, ώστε να βρίσκονται στο διάστημα $[0,1]$. Η κανονικοποίηση αυτή βελτιώνει τον υπολογισμό αποστάσεων και τη σταθερότητα του αλγορίθμου. Για την ταξινόμηση εφαρμόζεται ο αλγόριθμος k-Nearest Neighbors ($k=3$) με ευκλείδεια απόσταση. Ο k-NN είναι μη παραμετρικός αλγόριθμος, ο οποίος αποδίδει σε κάθε νέο δείγμα την κλάση που πλειοψηφεί μεταξύ των k κοντινότερων δειγμάτων του συνόλου εκπαίδευσης.

Η ακρίβεια στο test set είναι 35.3%, ποσοστό σαφώς υψηλότερο από την τυχαία πρόβλεψη (10%), αλλά σχετικά χαμηλό συνολικά. Ο πίνακας αποκαλύπτει σημαντικό αριθμό λανθασμένων ταξινομήσεων εκτός της διαγώνιου συνεπώς και σύγχυση μεταξύ ορισμένων κατηγοριών. Η εξέταση του confusion matrix στον αρχικό χώρο των pixel δείχνει ότι οι πιο έντονες ασάφειες εμφανίζονται στα ζεύγη bee–beaver, bear–baby, bottle–bed και bicycle–bed. Αυτές οι λανθασμένες ταξινομήσεις δεν οφείλονται απαραίτητα σε πραγματική σημασιολογική συγγένεια μεταξύ των κατηγοριών πιθανότερο είναι να προκύπτουν από ομοιότητες στη χρωματική κατανομή ή στη γενική μορφολογία των εικόνων σε τόσο χαμηλή ανάλυση (32×32), όπου οι λεπτομέρειες χάνονται και κυριαρχούν απλοποιημένα μοτίβα.

Το αποτέλεσμα θεωρείται αναμενόμενο, καθώς το CIFAR-100 είναι ιδιαίτερα απαιτητικό dataset και ο k-NN, χρησιμοποιώντας μόνο τις αρχικές τιμές των pixel ως χαρακτηριστικά, δεν μπορεί να

αξιοποιήσει τη χωρική δομή και τα ιεραρχικά μοτίβα των εικόνων, όπως συμβαίνει με πχ. τα CNNs , τα οποία είναι καταλληλότερα για προβλήματα αναγνώρισης εικόνας.

Accuracy: 0.353
Confusion matrix:

```
[[41 9 23 0 12 3 1 6 4 1]
 [13 44 15 3 12 3 1 5 4 0]
 [12 7 47 2 10 6 3 2 11 0]
 [19 10 33 21 7 5 0 4 1 0]
 [ 8 9 22 4 40 8 3 0 3 3]
 [ 2 3 14 0 10 54 1 0 7 9]
 [ 5 5 25 0 35 3 24 1 2 0]
 [ 9 21 13 2 14 3 0 34 2 2]
 [ 8 6 15 0 21 25 5 4 15 1]
 [ 1 4 11 2 16 27 1 4 1 33]]
```

Top Confusions:

bee misclassified as beaver: 35 times
bear misclassified as baby: 33 times
bottle misclassified as bed: 27 times
bicycle misclassified as bed: 25 times
bee misclassified as baby: 25 times

Εκπαιδευμένη αναπαράσταση μέσω autoencoder

Στο συγκεκριμένο μέρος της εργασίας υλοποιήθηκε και εκπαιδεύτηκε ένας fully connected autoencoder στο υποσύνολο των δεδομένων. Κάθε εικόνα $32 \times 32 \times 3$ μετατράπηκε σε διάνυσμα 3072 διαστάσεων (flatten) και κανονικοποιήθηκε στο διάστημα $[0,1]$, επιτρέποντας τη χρήση Sigmoid στο επίπεδο εξόδου ώστε η ανακατασκευή να παραμένει στο ίδιο εύρος τιμών [\[1\]](#).

```
AE_PyGfG(
  (encoder): Sequential(
    (0): Linear(in_features=3072, out_features=1024, bias=True)
    (1): ReLU()
    (2): Linear(in_features=1024, out_features=512, bias=True)
    (3): ReLU()
    (4): Linear(in_features=512, out_features=128, bias=True)
  )
  (decoder): Sequential(
    (0): Linear(in_features=128, out_features=512, bias=True)
    (1): ReLU()
    (2): Linear(in_features=512, out_features=1024, bias=True)
    (3): ReLU()
    (4): Linear(in_features=1024, out_features=3072, bias=True)
    (5): Sigmoid()
  )
)
```

Ο encoder αποτελείται από διαδοχικά πλήρως
συνδεδεμένα επίπεδα 3072 $\rightarrow$ 1024 $\rightarrow$ 512 $\rightarrow$
128 με ενεργοποίηση ReLU, ενώ ο decoder έχει συμμετρική δομή 128 $\rightarrow$ 512 $\rightarrow$ 1024 $\rightarrow$ 3072.
Η ReLU επιλέχθηκε λόγω των ευνοϊκών ιδιοτήτων σύγκλισης και της μείωσης του φαινομένου
vanishing gradients [\[2\]](#). Το bottleneck των 128 διαστάσεων ορίστηκε ως συμβιβασμός μεταξύ
ισχυρής συμπίεσης και επαρκούς ανακατασκευαστικής ικανότητας, σύμφωνα με τη θεωρία
αναπαραστατικής μάθησης μέσω autoencoders [\[3\]](#). Ως συνάρτηση κόστους χρησιμοποιήθηκε το

Mean Squared Error (MSE), συμβατό με τη μοντελοποίηση των pixel τιμών ως συνεχών μεταβλητών υπό Gaussian υπόθεση, όπου η ελαχιστοποίηση MSE ισοδυναμεί με μέγιστη πιθανοφάνεια [4]. Η εκπαίδευση πραγματοποιήθηκε με τον Adam optimizer (learning rate 1e-3), για 100 epochs και batch size 128. Μετά την εκπαίδευση, η latent αναπαράσταση $z = \text{Encoder}(x)$ χρησιμοποιήθηκε ως είσοδος σε ταξινομητή 3-NN, δεδομένου ότι η γεωμετρία του embedding χώρου επηρεάζει άμεσα την απόδοση distance-based ταξινομητών. Πραγματοποιήθηκαν δύο ελεγχόμενα πειράματα: (i) αντικατάσταση του MSE με SmoothL1 (Huber) loss για την αξιολόγηση της επίδρασης της συνάρτησης κόστους στη σταθερότητα των learned representations [5], και (ii) τροποποίηση της αρχιτεκτονικής με σταθερό bottleneck και loss, ώστε να απομονωθεί η επίδραση της παραμετρικής πολυπλοκότητας στη γενίκευση.

```
AE_PyGFG(
  (encoder): Sequential(
    (0): Linear(in_features=3072, out_features=2048, bias=True)
    (1): ReLU()
    (2): Linear(in_features=2048, out_features=1024, bias=True)
    (3): ReLU()
    (4): Linear(in_features=1024, out_features=256, bias=True)
    (5): ReLU()
    (6): Linear(in_features=256, out_features=128, bias=True)
  )
  (decoder): Sequential(
    (0): Linear(in_features=128, out_features=256, bias=True)
    (1): ReLU()
    (2): Linear(in_features=256, out_features=1024, bias=True)
    (3): ReLU()
    (4): Linear(in_features=1024, out_features=2048, bias=True)
    (5): ReLU()
    (6): Linear(in_features=2048, out_features=3072, bias=True)
    (7): Sigmoid()
  )
)
```

Συγκριτικός

Πίνακας

Πειραμάτων Fully Connected Autoencoder

Πείραμα	Αρχιτεκτονική	Loss Function	Latent Dim	3-NN Accuracy
Baseline	3072 → 1024 → 512 → 128	MSE	128	0.408
Loss Change	Ίδια με baseline	SmoothL1 (Huber)	128	0.402
Architecture Change	3072 → 2048 → 1024 → 256 → 128	MSE	128	0.359

Η baseline αρχιτεκτονική παρέχει τη βέλτιστη απόδοση 0.408, ενώ η αλλαγή loss (MSE → Huber) δεν επιφέρει ουσιαστική βελτίωση, υποδηλώνοντας ότι η γεωμετρία του latent χώρου είναι σχετικά σταθερή ως προς τη συνάρτηση κόστους. Η αύξηση του βάθους με σταθερό bottleneck οδηγεί σε σημαντική πτώση της ακρίβειας (0.359), δείχνοντας ότι η επιπλέον

παραμετρική πολυπλοκότητα δεν μεταφράζεται σε καλύτερη διαχωρισιμότητα υπό reconstruction loss.

Στην επόμενη φάση σχεδιάστηκαν και αξιολογήθηκαν τρεις εκδοχές convolutional autoencoder (CAE) στο υποσύνολο 10 κλάσεων του CIFAR-100. Η επιλογή των κλάσεων έγινε με σταθερό random seed (np.random.seed(0)), ώστε να χρησιμοποιείται το ίδιο σύνολο δεδομένων σε όλα τα πειράματα. Οι εικόνες (32×32×3) αναδιαμορφώθηκαν σε μορφή CHW και κανονικοποιήθηκαν στο διάστημα [0,1]. Η εκπαίδευση πραγματοποιήθηκε με τον Adam optimizer (learning rate 1e-3), για 100 epochs και batch size 128. Ως μέτρο αξιολόγησης της ποιότητας των αναπαραστάσεων χρησιμοποιήθηκε ταξινομητής 3-Nearest Neighbors (3-NN) πάνω στο latent space.

Στο πρώτο πείραμα (Baseline CAE) χρησιμοποιήθηκε μια απλή συνελκτική αρχιτεκτονική με τρία convolutional επίπεδα και δύο στάδια MaxPooling. Ο encoder καταλήγει σε tensor διαστάσεων 8×8×8, που αντιστοιχεί σε latent αναπαράσταση 512 διαστάσεων μετά από flatten. Ο decoder αποτελείται από δύο ConvTranspose2d επίπεδα για upsampling και τελικό Conv2d με ενεργοποίηση Sigmoid. Ως συνάρτηση κόστους χρησιμοποιήθηκε το Mean Squared Error (MSE). Η ακρίβεια του 3-NN στον latent χώρο ήταν 0.411, δείχνοντας ότι το μοντέλο μαθαίνει αναπαραστάσεις με διακριτική πληροφορία παρότι η εκπαίδευση είναι μη εποπτευόμενη.

```
ConvAutoencoder(  
    (encoder): Sequential(  
      (0): Conv2d(3, 32, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
      (1): ReLU(inplace=True)  
      (2): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)  
      (3): Conv2d(32, 16, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
      (4): ReLU(inplace=True)  
      (5): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)  
      (6): Conv2d(16, 8, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
      (7): ReLU(inplace=True)  
    )  
    (decoder): Sequential(  
      (0): ConvTranspose2d(8, 16, kernel_size=(3, 3), stride=(2, 2), padding=(1, 1), output_padding=(1, 1))  
      (1): ReLU(inplace=True)  
      (2): ConvTranspose2d(16, 32, kernel_size=(3, 3), stride=(2, 2), padding=(1, 1), output_padding=(1, 1))  
      (3): ReLU(inplace=True)  
      (4): Conv2d(32, 3, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
      (5): Sigmoid()  
    )  
  )  
)
```

Στο δεύτερο πείραμα διατηρήθηκε ακριβώς η ίδια αρχιτεκτονική και η ίδια διάσταση latent (512), αλλά αντικαταστάθηκε η MSE με τη SmoothL1 (Huber) loss. Η αλλαγή αυτή οδήγησε σε αύξηση της ακρίβειας του 3-NN σε 0.422. Η βελτίωση, αν και μικρή, υποδηλώνει ότι η επιλογή της συνάρτησης κόστους επηρεάζει τη γεωμετρία και τη σταθερότητα του latent χώρου, με τη Huber να οδηγεί σε ελαφρώς πιο διαχωρίσιμες αναπαραστάσεις.

Συγκριτικός Πίνακας Πειραμάτων Convolutional Autoencoder

Πείραμα	Αρχιτεκτονική	Loss Function	Latent Dim	3-NN Accuracy
Baseline	Conv(3→32) → MP → Conv(32→16) → MP → Conv(16→8)	MSE	512	0.411
Loss Change	Ίδια με baseline	SmoothL1 (Huber)	512	0.422
Architecture Change	Conv(3→32→32) → MP → Conv(32→64→64) → MP → Conv(64→8)	MSE	512	0.385
Baseline (dimension-matched with FCA)	Conv(3→32) → MP → Conv(32→16) → MP → Conv(16→2)	MSE	128	0.384

Τα αποτελέσματα δείχνουν ότι τα συνελκτικά autoencoders υπερέχουν των πλήρως συνδεδεμένων ως προς την 3-NN ακρίβεια, γεγονός που αποδίδεται στην επαγωγική μεροληψία των CNNs και στη χωρική δομή που ενσωματώνουν στις αναπαραστάσεις τους [6]. Επιπλέον, η ελαφρά βελτίωση που παρατηρήθηκε με τη χρήση της SmoothL1 (Huber) loss υποδηλώνει ότι οι robust reconstruction objectives οδηγούν σε πιο σταθερά και γεωμετρικά συνεκτικά embeddings [5]. Αντίθετα, η αύξηση του βάθους της αρχιτεκτονικής οδήγησε σε μείωση της απόδοσης, φαινόμενο που έχει συνδεθεί με ζητήματα γενίκευσης και υπερπαραμετροποίησης σε σύγχρονες μελέτες [7]. Τέλος, όταν η διαστατικότητα του λανθάνοντος χώρου εξισώθηκε στις 128 διαστάσεις, το FCAE παρουσίασε ελαφρώς υψηλότερη 3-NN ακρίβεια σε σχέση με το CAE. Το εύρημα αυτό υποδηλώνει ότι η αρχική υπεροχή του CAE δεν οφειλόταν αποκλειστικά στη συνελκτική αρχιτεκτονική, αλλά σε σημαντικό βαθμό στη μεγαλύτερη χωρητικότητα του embedding (512 διαστάσεις). Η βιβλιογραφία επισημαίνει ότι η διαστατικότητα και η γεωμετρία του representation space επηρεάζουν άμεσα την απόδοση ταξινομητών βασισμένων σε αποστάσεις ενώ η αυξημένη χωρητικότητα μπορεί να ενισχύσει τη διαχωριστική ικανότητα των embeddings [8].

EMBEDDINGS

Στο παρόν στάδιο της εργασίας συγκρίθηκε η επίδοση της εκπαιδευμένης αναπαράστασης (autoencoder) με δύο off-the-shelf προεκπαιδευμένα μοντέλα: CLIP και ResNet-18. Η αξιολόγηση πραγματοποιήθηκε με σταθερό ταξινομητή 3-Nearest Neighbors ($k=3$) και Ευκλείδεια απόσταση, ώστε η σύγκριση να αφορά αποκλειστικά τη γεωμετρία και τη διαχωριστική ικανότητα του embedding χώρου, χωρίς να επηρεάζεται από παραμέτρους εκπαίδευσης επιπλέον ταξινομητή. Η χρήση k-NN ως μέτρου ποιότητας embedding είναι σύμφωνη με τη βιβλιογραφία, καθώς η απόδοσή του εξαρτάται άμεσα από τη δομή και τη συνοχή του representation space [8].


Το CLIP αποτελεί πολυτροπικό μοντέλο contrastive μάθησης, το οποίο εκπαιδεύεται σε μεγάλης κλίμακας ζεύγη εικόνας-κειμένου. Μέσω contrastive objective, το μοντέλο μαθαίνει κοινό embedding χώρο όπου σημασιολογικά συναφείς εικόνες και κείμενα ευθυγραμμίζονται. Έχει αποδειχθεί ότι τα embeddings του CLIP είναι ιδιαίτερα μεταφέρσιμα και επιτυγχάνουν υψηλή απόδοση σε downstream tasks ακόμη και χωρίς fine-tuning [9]. Για την εξαγωγή των CLIP embeddings, οι εικόνες ανακλιμακώθηκαν σε 224×224 pixels και κανονικοποιήθηκαν σύμφωνα με τα προτεινόμενα mean και standard deviation του προεκπαιδευμένου μοντέλου. Η εξαγωγή χαρακτηριστικών πραγματοποιήθηκε σε inference mode (`model.eval()`, `torch.no_grad()`), χωρίς τροποποίηση των βαρών..

Το δεύτερο embedding προήλθε από το ResNet-18 [10], ένα residual convolutional νευρωνικό δίκτυο που εισήγαγε skip connections για τη σταθεροποίηση της εκπαίδευσης βαθιών μοντέλων. Τα residual networks έχουν αποδειχθεί ιδιαίτερα αποτελεσματικά στη μάθηση ιεραρχικών οπτικών χαρακτηριστικών και παρουσιάζουν ισχυρή μεταφερσιμότητα όταν προεκπαιδεύονται στο ImageNet [11]. Για το ResNet-18, οι εικόνες ανακλιμακώθηκαν σε 224×224 και κανονικοποιήθηκαν με τα ImageNet mean/std. Τα χαρακτηριστικά εξήχθησαν από το επίπεδο μετά το global average pooling (penultimate layer), αποδίδοντας embedding 512 διαστάσεων. Σε όλες τις περιπτώσεις χρησιμοποιήθηκε 3-NN με Ευκλείδεια απόσταση χωρίς περαιτέρω κανονικοποίηση.

CLIP :

CLIP embedding dim: 512


--- CLIP (512d) | 3-NN (k=3, Euclidean) ---
Accuracy: 0.8610







ResNet :

ResNet embedding dim: 512

--- ResNet-18 (512d) | 3-NN (k=3, Euclidean) ---
Accuracy: 0.8370



Παρακάτω είναι και τα αντίστοιχα PCA και t-SNE :



Η ανάλυση των confusion matrices δείχνει ότι στο CLIP οι περισσότερες κλάσεις ταξινομούνται σχεδόν διαγώνια, με περιορισμένες συγχύσεις κυρίως μεταξύ θαλάσσιων ειδών (turtle–whale) και οπτικά συγγενών ζώων (crab–otter). Στο ResNet-18 παρατηρείται ελαφρώς αυξημένη σύγχυση μεταξύ κατηγοριών με παρόμοια υφή ή σχήμα, γεγονός που αντανακλά λιγότερο ισχυρή σημασιολογική οργάνωση σε σχέση με το CLIP. Συγκριτικά με τα autoencoder embeddings, οι συγχύσεις είναι σημαντικά μειωμένες, επιβεβαιώνοντας ότι η ποιότητα της αναπαράστασης επηρεάζει άμεσα την απόδοση του k-NN.

Για το PCA τα CLIP embeddings (πάνω αριστερά) δείχνουν πιο ομαλή και δομημένη κατανομή, με μια καμπυλωτή διάταξη που υποδηλώνει ότι η κύρια διακύμανση συλλαμβάνει σημαντική σημασιολογική πληροφορία. Τα ResNet-18 embeddings (πάνω δεξιά) φαίνονται πιο «μπλεγμένα» στις πρώτες 2 συνιστώσες. Όσον αφορά το t-SNE (2D) στα CLIP embeddings (κάτω αριστερά) οι κλάσεις σχηματίζουν πιο καθαρά και συμπαγή clusters με καλύτερο διαχωρισμό. Στο ResNet-18 (κάτω δεξιά) υπάρχουν περισσότερες επικαλύψεις μεταξύ κλάσεων. Συμπερασματικά τα CLIP embeddings φαίνεται να έχουν καλύτερη εγγενή διαχωριστικότητα σε χαμηλές διαστάσεις, ιδιαίτερα στο t-SNE, κάτι που υποδηλώνει πιο ισχυρή σημασιολογική αναπαράσταση.

Τελικός συγκεντρωτικός πίνακας

Representation	Dim	Accuracy
Pixels	3072	0.353
FC AE	128	0.408
CAE (Huber)	512	0.422
CLIP	512	0.8610
ResNet	512	0.8370

Η σημαντική υπεροχή του CLIP έναντι των υπολοίπων embeddings μπορεί να αποδοθεί στο contrastive training objective του μοντέλου, το οποίο βελτιστοποιεί ρητά τη γεωμετρία του embedding χώρου ώστε σημασιολογικά συναφείς εικόνες να βρίσκονται κοντά μεταξύ τους και διαφορετικές να απομακρύνονται. Δεδομένου ότι ο k-NN βασίζεται αποκλειστικά σε μετρικές αποστάσεις, ένα embedding χώρο με τέτοιες ιδιότητες ευνοεί άμεσα την απόδοσή του. Να σημειωθεί πως για τα προεκπαιδευμένα embeddings (CLIP, ResNet) εφαρμόστηκε L2 normalization, καθώς η γεωμετρία τους βασίζεται σε κατευθυντικές ομοιότητες. Αντίθετα, για τα embeddings του autoencoder εφαρμόστηκε standardization (zero mean, unit variance), ώστε να εξισορροπηθούν οι διαστάσεις του latent χώρου πριν τον 3-NN ταξινομητή.

Μικρή ερευνητική ερώτηση

Η συγκεκριμένη ερώτηση αναφέρθηκε και προηγουμένως, όπου για την απομόνωση της επίδρασης της αρχιτεκτονικής, συγκρίθηκαν fully connected και convolutional autoencoders σε ίδια διάσταση λανθάνοντος χώρου (128 διαστάσεις), στο ίδιο σύνολο δεδομένων και με τον ίδιο ταξινομητή (3-NN). Τα αποτελέσματα έδειξαν ότι:

Autoencoder	Accuracy
Fully Connected AE (128-d)	0.408
Convolutional AE (128-d)	0.384

Άρα, η βελτίωση από 128→512 dims δεν οφείλεται μόνο στην CNN αρχιτεκτονική, αλλά και στην αυξημένη χωρητικότητα του χώρου που επιτρέπει καλύτερη διατήρηση των τοπικών δομών που εκμεταλλεύεται ο k-NN.

Πρόσφατη θεωρητική ανάλυση [12] δείχνει ότι η διατήρηση της δομής των k-nearest neighbors σε Ευκλείδειο χώρο εξαρτάται από τη διαστατικότητα του embedding. Αν και το αποτέλεσμα αυτό δεν συνεπάγεται ότι η αύξηση της διάστασης οδηγεί μονοτονικά σε καλύτερη ακρίβεια, υπογραμμίζει τον θεμελιώδη γεωμετρικό ρόλο της διαστατικότητας σε distance-based μεθόδους, γεγονός που είναι συνεπές με τα εμπειρικά μας ευρήματα.

Τεκμηρίωση

Στην παρούσα εργασία διερευνήθηκε η επίδραση της αναπαράστασης των δεδομένων στην απόδοση ενός ταξινομητή k-Nearest Neighbors ($k=3$), χρησιμοποιώντας υποσύνολο του συνόλου δεδομένων CIFAR-100. Αρχικά αξιολογήσαμε την απόδοση του ταξινομητή στον αρχικό χώρο των pixel. Τα αποτελέσματα έδειξαν χαμηλή ακρίβεια, γεγονός που μπορεί να εξηγηθεί από τη μεγάλη διαστατικότητα των δεδομένων αλλά και από το ότι οι ακατέργαστες τιμές των pixel δεν μπορούν να αποτυπώσουν σημασιολογικές πληροφορίες για τις εικόνες.

Στη συνέχεια, εξετάστηκαν αναπαραστάσεις που προκύπτουν από την εκπαίδευση autoencoders. Παρατηρήθηκε ότι οι learned representations οδηγούν σε βελτιωμένη απόδοση του k-NN σε σχέση με τον αρχικό χώρο των δεδομένων. Επιπλέον, τα πειράματα έδειξαν πως και η αρχιτεκτονική του μοντέλου αλλά και η συνάρτηση κόστους επηρεάζουν τη γεωμετρία του λανθάνοντος χώρου. Συγκεκριμένα, -σχετικά με την ερευνητική ερώτηση- τα convolutional autoencoders εμφάνισαν καλύτερη απόδοση όταν η διάσταση του latent space ήταν μεγαλύτερη, κάτι που πιθανότατα σχετίζεται με την ικανότητά τους να αξιοποιούν τη χωρική δομή των εικόνων.

Στο τελικό στάδιο της εργασίας, μέσω της σύγκρισης με προεκπαιδευμένα embeddings φάνηκε πως τα μοντέλα μεγάλης κλίμακας, όπως το CLIP και το ResNet-18, επιτυγχάνουν σημαντικά υψηλότερη ακρίβεια. Η υπεροχή αυτή οφείλεται στο γεγονός ότι τα μοντέλα αυτά έχουν εκπαιδευτεί σε πολύ μεγάλα σύνολα δεδομένων, άρα έχουν μάθει πιο πλούσιες και σημασιολογικά οργανωμένες αναπαραστάσεις.

Συνολικά, τα αποτελέσματα της εργασίας υποδεικνύουν ότι η ποιότητα της αναπαράστασης των δεδομένων αποτελεί κρίσιμο παράγοντα για την απόδοση distance-based ταξινομητών. Τα προεκπαιδευμένα embeddings έχουν σαφές πλεονέκτημα έναντι αναπαραστάσεων που εκπαιδεύονται από την αρχή σε περιορισμένα σύνολα δεδομένων.

References:

[1] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.

<https://www.deeplearningbook.org/contents/autoencoders.html>

[2] Xavier Glorot, Antoine Bordes, Yoshua Bengio. Deep Sparse Rectifier Neural Networks. Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics (AISTATS 2011), Proceedings of Machine Learning Research (PMLR) 15:315–323, 2011

https://www.researchgate.net/publication/215616967_Deep_Sparse_Rectifier_Neural_Networks

[3] G. E. Hinton and R. R. Salakhutdinov, “Reducing the Dimensionality of Data with Neural Networks, 2006

<https://www.science.org/doi/10.1126/science.1127647>

[4] C. M. Bishop, *Pattern Recognition and Machine Learning*. New York, NY, USA: Springer, 2006.

<https://www.microsoft.com/en-us/research/wp-content/uploads/2006/01/Bishop-Pattern-Recognition-and-Machine-Learning-2006.pdf>

[5] C. Zhou and R. C. Paffenroth, “Anomaly Detection with Robust Deep Autoencoders,” in *Proc. 23rd ACM SIGKDD Int. Conf. Knowledge Discovery and Data Mining (KDD '17)*, 2017.

<https://doi.org/10.1145/3097983.3098052>

&

<https://projecteuclid.org/journals/annals-of-mathematical-statistics/volume-35/issue-1/Robust-Estimation-of-a-Location-Parameter/10.1214/aoms/1177703732.full> (Huber 1964)

[6] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.

<https://www.deeplearningbook.org/contents/convnets.html>

[7] P. Nakkiran, G. Kaplun, Y. Bansal, T. Yang, B. Barak, and I. Sutskever, “Deep Double Descent: Where Bigger Models and More Data Hurt,” in *Proc. Int. Conf. Learning Representations (ICLR)*, 2021

<https://arxiv.org/abs/1912.02292>

[8] T. Wang and P. Isola, “Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere,” in *Proc. Int. Conf. Machine Learning (ICML)*, 2020.

<https://arxiv.org/abs/2005.10242>

[9] A. Radford, J. W. Kim, C. Hallacy, A. Ramesh, G. Goh, S. Agarwal, et al., “Learning Transferable Visual Models From Natural Language Supervision,” in *Proc. Int. Conf. Machine Learning (ICML)*, 2021.

<https://arxiv.org/abs/2103.00020>

[10] K. He, X. Zhang, S. Ren, and J. Sun, “Deep Residual Learning for Image Recognition,” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2016

[10.1109/CVPR.2016.90](https://doi.org/10.1109/CVPR.2016.90)

[11] S. Kornblith, J. Shlens, and Q. V. Le, “Do Better ImageNet Models Transfer Better?” in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, 2019

<https://arxiv.org/abs/1805.08974>

[12] D. Avdiukhin, V. Chatziafratis, O. Fischer, and G. Yaroslavtsev, “Embedding Dimension of Contrastive Learning and k-Nearest Neighbors,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.

<https://dl.acm.org/doi/10.5555/3737916.3739225>

